

大语言模型在医疗健康领域的应用现状与前景展望*

陈紫林¹ 祝帆帆¹ 罗宇昕² 张伟^{3△} 卢龙^{1△}

摘要:系统梳理了医疗大语言模型的开发方式、模型类型与应用现状,并指出其在医疗场景下所面临的独特且更为复杂的伦理安全挑战。相较于其他人工智能技术,医疗大语言模型在数据安全与隐私保护、算法偏见与公平性、医患关系重构、责任归属不清以及跨领域迁移中的伦理风险等方面呈现出更深层次的问题。因此,推动医疗大模型的实际落地,既需持续突破技术瓶颈、提升生成内容的准确性与可解释性,也需正视其潜在的伦理风险与社会影响。将医疗大语言模型嵌入临床工作流程,应遵循自主、有利、不伤害与公平四项基本伦理原则。

关键词:医疗健康大模型, 实现范式, 应用场景, 伦理挑战

中图分类号: R-05 **文献标识码:** A **文章编号:** 1002-0772(2025)12-0032-06

DOI: 10.12014/j.issn.1002-0772.2025.12.07

Applications and Future Prospects of Large Language Models in Healthcare CHEN Zilin¹, ZHU Fanfan¹, LUO Yuxin², ZHANG Wei³, LU Long¹. 1. College of Information Management, Wuhan University, Wuhan, 430072 China; 2. Maynooth International Engineering College, Fuzhou University, Fuzhou 350108, China; 3. Information Center, General Hospital of the Central Theater Command of the People's Liberation Army, Wuhan, 430070, China

Abstract: This paper provides a systematic review of the development approaches, model types, and current applications of large language models (LLMs) in the healthcare domain. It highlights the unique and increasingly complex ethical and safety challenges these models face in healthcare contexts. Compared with other artificial intelligence technologies, LLMs exhibit deeper issues related to data security and privacy protection, algorithmic bias and fairness, the reconfiguration of doctor-patient relationships, ambiguity in the attribution of responsibility, and ethical risks arising from cross-domain transfer. The practical implementation of LLMs in healthcare requires not only continuous technological advancement to improve the accuracy and interpretability of generated content, but also a careful consideration of their potential ethical risks and societal implications. The integration of LLMs into clinical workflows should be guided by the four fundamental ethical principles of autonomy, beneficence, non-maleficence, and justice.

Key Words: large language models in healthcare, implementation paradigms, application scenarios, ethical challenges

当前人工智能发展迅速,人工智能已初步应用于辅助诊断、护理等医疗领域^[1],并在电子病历处理、智能设备等场景中取得成效^[2]。然而传统的人工智能系统在医疗复杂性面前仍面临数据匮乏、泛化能力弱和场景适应性差等问题。

随着预训练语言模型(pre-trained language models, PLMs)参数规模的扩大,“大语言模型”(以下简称“大

模型”)应运而生,其指代具有数十亿或数百亿参数的模型。大模型基于Transformer^[3]架构,通过自注意力机制和奖励微调,具备强大的上下文理解和生成能力。在医疗领域,大模型可整合海量异构数据,支持诊断建议、临床决策与个性化治疗,见图1。以谷歌于2023年5月发布的Med-PaLM2为例,其在MedQA数据集上的准确率达到86.5%,一经问世就树立了新的业界标杆^[4]。2025年初,DeepSeek推动了医疗健康领域的智能革新。其凭借多模态处理能力、混合专家(MoE)架构、动态参数激活等机制,实现了低成本、高质量的智能生产和开源共享^[5]。




图1 大模型在特定领域的应用工作流程

*基金项目: 2023年北京医院管理局临床医学发展专项资金项目(ZLRK202333)

1. 武汉大学信息管理学院 湖北武汉 430072

2. 福州大学梅努斯国际工程学院 福建福州 350108

3. 中国人民解放军中部战区总医院信息中心 湖北武汉 430070

作者简介: 陈紫林(2002—),女,硕士研究生,研究方向:医疗大模型。

通信作者: 张伟(1977—),男,副主任技师,研究方向:医疗信息化管理。E-mail: 84596174@qq.com

卢龙(1976—),男,博士,教授,研究方向:医学影像分析、生物信息学、深度学习。E-mail: bmiwhu@163.com

△为共同通信作者

当前,多方力量正在推进“医疗健康大模型”的构建与应用,尝试将语言、图像和多模态数据整合于一体,服务于临床诊疗、医学研究和健康管理等多种场景。然而,现有医疗健康大模型仍存在一系列未解决的问题,包括缺乏透明度和可解释性、生成“幻觉”内容等^[6]。本文将围绕以下问题展开讨论:(1)现有的开发实现范式是什么?(2)从输入数据模态划分,医疗健康大模型的类型有哪些?(3)医疗健康大模型的应用现状如何?应用生态是怎样的?应用场景有哪些?(4)医疗健康大模型的伦理挑战和机遇有哪些?

1 医疗健康大模型的实现范式

本节介绍了医疗健康大模型的四种实现方式,见图 2。值得注意的是,许多大模型也采用了组合策略进行训练,这些策略融合了“指令/任务微调与提示工程”或“预训练与微调”等多元方法,以实现更高效和精准的医疗健康应用。



图 2 医疗健康大模型实现的四种范式

1.1 预训练垂类大模型

这类范式直接在大型生物、医学、健康相关语料库上随机初始化参数预训练大模型,避免了领域不匹配问题。训练目标包括掩码建模或者自回归建模等,使用对比学习或强化学习进行优化等。例如,纽约大学开发的 NYUTron^[7],其基于 BERT 框架并在 NYU Notes 数据集进行掩码语言建模训练,并在完整电子病历上验证其效果。

1.2 在通用大模型的基础上预训练

该范式在通用语言模型的初始化参数基础上,使用医疗数据继续预训练,融合通用知识与领域需求,并降低训练成本。FFA-GPT^[8]在荧光素眼底血管造影图像及中文报告数据上预训练 BLIP 模型,实现了视网膜的精确识别与清晰连贯的中文报告生成。上海交通大学团队研发的 PMC-LLaMA^[9]在 LLaMA 模型的基础上,使用海量医学论文和医学教科书训练,提升 Zero-shot 任务生成能力。

1.3 指令/任务微调

此范式通过任务微调、指令微调或基于人类反馈的强化学习微调,使预训练模型适应下游任务。任务微调方法通常涉及在小规模的数据集上进行微调以便模型更精准解决特定问题,例如 DRG-LLaMA^[10]模型在 MIMIC-IV 数据集中的出院摘要进行疾病诊断相关分组预测任务的训

练,提高医疗记录分析和疾病分类的性能。指令微调方法是通过监督学习或强化学习,确保大模型的响应回答与特定领域的知识保持一致,如 ChatDoctor^[11]使用疾病信息与医患对话数据进行微调,提升理解患者需求的能力。也有学者利用人类偏好数据训练奖励模型,并通过人类偏好的强化学习(reinforcement learning from human feedback, RLHF)技术优化响应,例如,美国德克萨斯大学团队开发了一个能够将自由文本的临床笔记转换为结构化数据的工作流程^[12],该过程应用了人类反馈强化学习技术来提高语言模型对医学术语和指南的理解,从而减轻大模型的幻觉问题。

1.4 提示工程

提示工程通过设计输入提示来控制大模型输出,包括人工硬提示(自然语言表示)和机器自动优化的软提示(特征向量表示)。如谷歌推出的 Med-PaLM^[13]基于指令微调与知识对齐的 PaLM 模型,在 USMLE 问题中首次超过及格分数,在 MedQA 数据集上准确率为 67.2%。

2 医疗健康大模型的类型

医疗健康领域涵盖医学文本、图像、生命组学、蛋白质结构等多模态数据。通过针对不同模态数据微调基座模型可完成自然语言处理、计算机视觉和图学习等任务。本文根据输入数据的不同模态将医疗健康大模型划分为四类:文本型、视觉型、多模态型和其他类型,见图 3。




图 3 医疗健康大模型的类型

2.1 文本型大模型

文本型大模型主要通过文本对话交互,用于医学文本生成、知识问答和医疗建议生成等任务,是当前医疗大模型中数量最多的类型。医疗健康大模型是通用大模型的领域增强版本,基于 GPT、BERT、T5 等架构,使用医学文本数据进行再训练或微调以适应领域需求。例如, BioBERT 在大规模生物医学语料上预训练后在特定自然语言处理(natural language processing, NLP)任务上微调^[11]。其他代表性模型可见表 1。

表 1 现有医疗健康大模型总结

大模型	发布时间	研发团队	输入数据类型	功能
MEDIC	2024年5月	亚马逊团队	文本	模拟药剂师的推理
FFA-GPT	2024年5月	香港理工大学团队和中山眼科中心等机构	多模态	FFA报告生成和交互式问答
DRG-LLaMA	2024年2月	明尼苏达州曼卡托市梅奥诊所	文本	疾病诊断相关分组预测任务
GatorTronGPT	2023年9月	佛罗里达大学团队	文本	生物医学自然语言处理、文本生成
XrayGLM	2023年6月	澳门理工大学团队	多模态	胸部X光片识别和预测
NYUTron	2023年6月	纽约大学团队	文本	临床笔记预测任务
Med-PaLM	2023年5月	谷歌团队	多模态	医学知识检索、医疗问答、图像解读
ChatDocotr	2023年5月	德克萨斯南西医学中心放射肿瘤科等	文本	医疗对话
PMC-LLaMA	2023年4月	上海交通大学团队	文本	中文医学问答、推理
RETFound	2023年2月	伦敦大学等	视觉型	视网膜疾病识别与预测
BioMedLM	2022年12月	斯坦福基础研究中心	文本	医疗问答
文心生物计算大模型	2022年5月	百度	分子结构	生物研究

2.2 视觉型大模型

视觉大模型(视觉-语言大模型)主要用于医学图像识别、图像标注生成、图像合成、图像预测等任务。通过医学成像数据或图像-文本对齐预训练,学习视觉-语言关联以执行跨模态任务。这类模型可自动生成报告、标注图像与视频,并辅助临床诊断等。在医疗健康领域,典型代表有 FFA-GPT、PETFound、EyeGPT 等。以 PETFound^[14]大模型为例,它在超过 160 万张标注的视网膜图像上使用自监督学习方法训练,在眼部疾病诊断/预后及系统性疾病预测等任务中都表现出极佳的性能。

2.3 多模态型大模型

多模态大模型代表了多种类型大模型融合的趋势。可综合分析不同模态的医学数据,实现统一的架构和任务处理。Med-PaLM 模型便支持处理临床文本、医学图像和基因组数据等医疗健康数据。此外,上海人工智能实验室在 2023 年 6 月发布了全球首个医疗多模态基础模型群“OpenMEDLab 浦医”,支持十余种数据模态。大模型的融合应用将进一步推进医疗创新和其在实际应用中的落

地与普及。

2.4 其他大模型

生命科学数据不仅包括文本和图像,还涵盖分子结构、化学式等,处理此类数据需特定模型。例如,华为的盘古药物分子大模型和百度的文心生物计算大模型,均支持可用于药物研发与生物研究的化学结构数据分析。此外,图学习大模型利用图神经网络等图学习技术将生物序列数据图形化,并通过图算法进行分析和推理,用于预测蛋白质结构、设计药物、分析基因组等。语言条件多智能体大模型则以语言作为多个大模型之间的中介接口,能协调多个模型,可以实现远程会诊、智能导诊、操控医疗机器人等。

3 医疗健康大模型的应用现状

3.1 医疗健康大模型应用生态

医疗健康大模型的生态主要由“上游基础层-中游模型层-下游应用层”构成,明确了其学科与产业边界以便系统理解,见表 2。由于医疗健康数据涉及个人健康信息,且医疗场景要求遵守行业规范和伦理标准,因此,数据安全和监管治理在发展中至关重要。

表 2 医疗健康大模型应用生态

架构层	涉及范围
上游基础层	算力基础设施:芯片、服务器、通信网络、云计算服务等;数据基础设施:数据采集、数据标注、医疗数据库、多模态数据库等
中游模型层	算法研发:大语言模型、视觉大模型、图学习大模型、语言条件多智能体大模型、多模态大模型;模型管理维护:系统管理、应用程序编程接口管理、数据处理
下游应用层	服务用户:患者、医护人员、生物医学科研人员、药械研发企业、医疗保险企业、监管机构等;应用场景:生命科学研究、药械研究、医学影像、医疗问答和智能问诊、辅助医疗和临床决策支持、医疗记录、医院运营、行政管理、个人健康管理

上游基础层在人工智能大模型研发和落地过程中扮演着重要角色,包括算力基础核心设施和数据基础设施。2024 年 3 月,英伟达推出了新一代 GPU 架构 BLACKWELL 以支持人工智能训练需求。同时构建一个全面的软件生态系统,包括基础模型、推理微服务和数字孪生等。现有公开的医疗英文数据集包括: I2B2、N2C2、PubMedQA、MedMCQA、USMLE 等,中文数据集包括: CBLUE、CNMLE、CMB 等。值得注意的是,佛罗里达大学团队基于 BERT 框架利用 GatorTronGPT 生成的 200 亿文本,开发具有 345 百

万参数的大模型 GatorTronS,研究表明合成文本训练的 NLP 模型性能优于真实临床文本模型,揭示了大模型在提供生物医学数据资源方面的增益潜力,为数据稀缺问题提供解决方案。

中游模型层负责大模型算法研发和管理维护,承担执行包括自然语言处理、图像识别、语音语义识别等生物医学任务。高效的管理运维保障性能稳定,促进模型的持续优化和升级。其发展需学术界和工业界的共同参与,通过跨学科的合作推动模型层的创新,同时模型层也是应用

落地的基础,为下游应用层提供强大的动力。

下游应用层连接模型和用户,将大模型的能力转化为应用于药、械、医、健等多场景。其在生命科学和药械研发应用起步早,发展快,成果显著。当前应用涵盖医学影像分析、医疗问答与智能问诊、辅助诊疗及临床决策支持、医学信息提取与生成、行政流程优化、个人健康管理、医保与商保服务以及医学教育等多个领域,应用场景持续扩展。

3.2 医疗健康大模型应用场景

科研教育领域应用包括生命科学研究、药械研究、医学教育等多个方面,见图 4。大型科技公司正积极投入生物医药研究,推动相关技术的发展。如英伟达推出生物医药基础模型云服务平台 BioNeMo,提供了生成式化学、蛋白质语言和结构预测模型,支持蛋白质、DNA 和生物化学数据处理,加速药物研发;英特尔研发了万亿参数的生成式模型 AuroragenAI,基于生物学、医学、物理学等结构化数据进行训练,加速科研和新药研发。此外,大模型可辅助医学教育,提供医学信息和互动案例^[15],实现个性化学习体验,提高教育质量和学习效果;然而其仍面临许多挑战,如学术不端行为的风险、过度依赖人工智能削弱批判性思维技能以及对大模型生成医学内容准确性和可靠性的担忧^[16]。




图 4 医疗健康大模型的应用场景

在临床实践上,应用场景涵盖智能问诊、辅助医疗和临床决策支持等。一些研究对大模型整合到临床实践流程中持积极态度。例如,有研究评估显示 GPT-4 对常见骨科疾病的治疗建议的有效性,表明模型提供的建议很大程度上准确且具有临床价值,但同时也指出它们存在理解患者整体情况的局限^[17]。有学者通过使用大模型来准确解释慢性乙型肝炎病毒感染管理的医学指南,以改进临床决策支持系统,展示了大模型整合到医疗实践中的潜力^[18]。还有研究评估显示大模型具有优秀回答复杂神经外科问题的潜力,但它们在循证医学方面存在不足。预计未来将有更多围绕医疗大模型展开的新研究,特别在医学细分领域,如基于证据的临床信息^[19]。但也有学者持保守观点,认为目前可用的大型语言模型在现实临床实践中并不足

以安全部署,因为当前最先进的大模型诊断能力不完善,极大可能对患者健康构成严重风险^[6]。且缺乏标准化的方法和基准会延迟其在现实临床环境中的安全部署。此外,虽然大模型为医疗健康领域带来了变革性潜力,但对问责制、准确性和数据安全性的担忧仍然存在^[20],需要通过进一步的研究、政策制定和技术改进来解决。

医院运营方面的典型应用场景包括医疗记录、行政管理、个人健康管理。目前,人工智能技术已成功整合到电子健康记录系统中。已有一些公司和大型医院采取了这些技术。例如,纽约大学团队基于一家大型医疗保健系统的电子病历训练了 NYUTron,其可与现有医疗工作流程无缝集成;但对来自不同临床部门的人口统计特征的患者记录敏感,并且有性能波动。2025 年 2 月,甘肃联勤保障部队第 940 医院成功部署国产 DeepSeek-R1 大模型,实现病历文书辅助生成、科研申报书智能审查等功能^[21],也可应用于一般场所的运营服务中。使用大模型还可以显著简化临床后工作流程,以确保患者收到有关其健康状况、治疗计划和后续护理的全面且对用户友好的出院提示^[22]。然而,由于大模型存在一些潜在问题,例如,患者数据安全和隐私风险、误导风险、伦理风险以及决策偏见和沟通不准确风险,仅经过充分验证、输出可靠且鲁棒的大模型才可被医院运营工作流程中正式采用^[23]。

4 医疗健康大模型应用面临的挑战和机遇

4.1 医疗健康大模型的应用挑战

4.1.1 可靠性挑战

医疗健康大模型发展首先面临缺乏统一评估标准的问题,这导致不同模型性能难以客观比较、验证和重现,从而降低了模型的可信度。其次,在处理常识问题时,大模型可能会生成不正确或无意义的内容,特别在医疗领域,“幻觉”问题目前仍是医疗健康大模型实现应用落地的重大挑战之一。此外,模型的“黑箱”特性导致其生成结果缺乏可解释性不足和一致性,可能引发专业人士和患者的不信任,同时这种不透明性可能导致模型的错误无法被及时发现和修正。最后,保持回答的一致性和准确性对于用药建议、问诊等关键问题尤为重要。为解决这些问题,需建立标准化的评估体系,提高模型的透明度、可解释性和可信度,并加强对模型输出的验证和监控,确保医疗健康大模型的可靠性。

4.1.2 伦理安全挑战

大模型的生成内容可能对人工智能伦理安全带来潜在挑战,包括激化偏见与歧视,传播虚假信息,激发医患关系矛盾,形成新的科研诚信风险等现象。

第一,数据安全与隐私保护问题。隐私保护在大模型训练和用户交互中至关重要。多数大模型是由技术公司开发,将患者数据上传至外部服务器将引发隐私和监管问题,而所需的高昂的计算资源也会阻碍医院本地部署。用户交互时可能无意识暴露敏感数据^[24]。模型训练涉及敏

感医疗数据时需遵循相关法规,实施数据访问控制、审计跟踪、数据脱敏等合规措施^[25];例如,上海医疗大模型检测验证中心通过资质审查、数据脱敏和全程审计跟踪,确保模型临床应用合规。而 DeepSeek 的本地化部署方案虽降低算力成本,但基层医院依赖云端处理时仍面临延迟与隐私泄露风险^[26]。此外,在大模型的使用过程中,需制定专门的隐私保护指南并对医疗专业人员进行培训。

第二,偏见和公平性问题。大模型在医疗领域的偏见表现为诊断准确性差异、治疗建议偏差及患者代表性不足等。研究显示,ChatGPT 生成的临床病历鉴别诊断存在种族、民族、性别等刻板印象,引发了对大模型在临床工作流程中传播或加剧健康差异的潜在担忧^[27]。因此,需持续监测和评估模型公平性,降低偏见传播风险。大模型中的潜在偏见来源于训练数据和模型的训练、推理、评估、部署等环节。其中训练数据是大模型产生偏见输出的关键原因,训练数据缺乏多样性会掩盖不同社会群体特征,导致模型泛化不足或偏向多数群体^[28]。例如,北京协和医院的罕见病模型“协和·太初”,因依赖头部医院数据,需借助小样本学习提升泛化能力,避免基层诊断偏差。同样,若基层医疗大模型采用三甲医院数据训练,可能因疾病谱差异导致误诊率上升^[29]。

第三,对医患关系的影响。尽管大模型在一定程度上能够为患者提供便利,并缓解部分就医难问题,但其固有的“幻觉”问题使其输出信息准确性存疑。医生在使用大模型时须严格审核生成内容,避免盲目依赖,否则可能导致患者受误导而受损。此外,过度依赖大模型还可能削弱医患直接沟通。患者若过度依赖人工智能模型获取信息会减少与医生的互动,从而限制医生全面了解患者的病情和背景,可能进一步影响治疗效果。生成式人工智能的介入形成了医生-患者-人工智能的三方互动模式,对传统伦理关系构成挑战,亟待构建新伦理框架^[30]。

第四,责任归属模糊性问题。大模型输出引发的医疗风险责任归属问题亟须系统化法律框架与责任分担机制。一方面,应明确模型开发者在算法缺陷、训练数据偏差等方面的法律责任;另一方面,医疗机构和医务人员在模型使用过程中的操作不当、依赖过度等行为亦需承担相应责任。目前,我国于 2023 年 7 月出台的《生成式人工智能服务管理暂行办法》主要规制服务提供者,对开发者责任界定尚不充分^[31]。在监管实践中,若医疗大模型被定位为辅助诊断工具,依据《医疗器械监督管理条例》,其应作为第三类医疗器械报国家药品监督管理局审批,并需系统性临床验证。尽管部分模型(如 MedGPT)在测试阶段展现出与临床医生诊断结果高达 96% 的高度一致性,其在真实医疗场景中仍需通过伦理审查、合规性评估及多中心临床试验等确保安全有效可控^[32]。

第五,跨领域迁移伦理风险。医疗大模型的跨领域迁移面临特殊挑战,细分领域数据异质性加剧了难度。例如,

瑞金医院的“瑞智病理大模型”聚焦单病种诊断,借助小样本学习提升迁移精度,防止跨科室误判^[33]。同时不同国家和地区医疗数据的伦理和法律规范差异,增加了迁移风险复杂性。

大模型在跨领域迁移时可能面临伦理风险管理的多重挑战。一方面,医疗细分领域诊疗标准差异可能导致模型迁移时传播不准确甚至有害的信息^[34]。例如,在内科病历数据上训练的模型应用于儿科领域时,可能因年龄相关的病理特征差异而得出不可靠的结论;另一方面,数据分布偏差可能导致模型性能显著下降,进而加剧医学不公平性并引发伦理争议。因此,亟须对细分领域输出进行严格评估,评估指标应包括但不限于预测结果的准确性、偏差和公平性,以及生成内容是否符合循证医学原则。

4.2 医疗健康大模型的应用机遇

4.2.1 医学上多模态实现的探索

多模态大模型能融合分析多种医学数据,具有更加深入理解医学知识的潜力。不同数据模态提供互补或重叠的患者诊疗信息,可克服单模态模型仅捕捉局部信息的局限,从而提高诊断与治疗准确性,是人工智能诊疗产品临床落地的关键。

4.2.2 医疗健康管理智能化、个性化

大模型将推动个人健康管理向个性化、智能化和主动化转变。细分领域细分场景的模型可帮助用户在医院和非医院场景中解决医疗健康相关问题,医疗健康大模型的落地应用有望成为生活必备的健康工具。科研领域也有大模型个性化发展方向的研究。例如,零样本表型化方法有助于加速研究和改进临床工作,在未来推动个性化医疗工具的发展^[35]。

4.2.3 补足人类认知的局限,与人类价值体系相契合

随着医疗专业的不断细分,不同医学学科间逐渐形成了认知壁垒。医疗健康大模型作为一种工具,能有效补充人类在这些专业领域的认知局限^[36],提升整个医学体系的深度和广度。这种提升不仅限于理论知识层面,更可实际提高医疗人员的工作效率与质量,降低患者获取医疗信息的门槛。同时,其应用还有助于缩小城乡医疗水平差距,促进医疗服务均等化,更好地体现人类社会的价值追求。

4.2.4 完善复杂的医疗体系,推动医疗领域全面发展

大模型在医疗领域的应用,不仅能够为医疗服务提质增效,缓解专家资源稀缺的问题,还能够有效应对医学发展不平衡的挑战。特别是在慢性病管理方面,大模型支持智能化管理与决策,助力应对老龄化社会带来的挑战。此外,大模型可加速医学科研的进程,推动医学领域的持续创新与发展。

5 结语

在人工智能已初步应用于医疗健康领域的背景下,大语言模型的出现加速了医疗与人工智能的结合。本文围绕医疗健康大模型的四种实现范式及数据模态分类进行综述,介绍其应用现状与生态,并从教育研究、临床实践、

医院运营三方面阐述应用场景与现状。最后,本文总结了大模型在医疗健康领域的应用挑战与机遇,重点强调伦理安全挑战。本文认为,要实现医疗健康大模型的落地需要不断突破技术阻碍,提高大模型生成内容的可靠性,又要重视其潜在的伦理安全问题。将大模型整合到医疗工作流程需遵循:自主性原则,确保患者知情自主决定;有利原则,保障患者的最佳利益;不伤害原则,避免给患者造成健康损害;公平性原则,保证公平获取医疗资源。

参考文献

- [1] 金春林,何 达. 人工智能在医疗健康领域的应用及挑战[J]. 卫生经济研究, 2018, 35(11): 3-6.
- [2] 孔 鸣,何前锋,李兰娟. 人工智能辅助诊疗发展现状与战略研究[J]. 中国工程科学, 2018, 20(2): 86-91.
- [3] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//RANZATO M, BEYGEZIMMER A, DAUPHIN Y, et al. Advances in Neural Information Processing Systems 30: NIPS 2017. Long Beach: Curran Associates, Inc., 2017.
- [4] SINGHAL K, TU T, GOTTWEIS J, et al. Towards Expert-Level Medical Question Answering with Large Language Models[EB/OL]. (2023-05-16)[2024-12-13]. <https://arxiv.org/abs/2305.09617>.
- [5] 谢新水. 智能跃迁、开源创新与主权 AI: DeepSeek 现象推动人工智能开源创新生态体系建设[J]. 电子政务, 2025(3): 40-48.
- [6] HAGER P, JUNGMANN F, HOLLAND R, et al. Evaluation and mitigation of the limitations of large language models in clinical decision-making[J]. *Nat Med*, 2024, 30(9): 2613-2622.
- [7] JIANG L Y, LIU X C, NEJATIAN N P, et al. Health system-scale language models are all-purpose prediction engines[J]. *Nature*, 2023, 619 (7969): 357-362.
- [8] CHEN X, ZHANG W, XU P, et al. FFA-GPT: An automated pipeline for fundus fluorescein angiography interpretation and question-answer[J]. *NPJ Digit Med*, 2024, 7(1): 111.
- [9] WU C, ZHANG X, ZHANG Y, et al. PMC-LLaMA: Further fine tuning llama on medical papers[EB/OL]. (2023-09-13)[2024-12-11]. <https://arxiv.org/abs/2304.14454>.
- [10] WANG H, GAO C, DANTONA C, et al. DRG-LLaMA: Tuning LLaMA model to predict diagnosis-related group for hospitalized patients[J]. *NPJ Digit Med*, 2024, 7(1): 16.
- [11] LI Y, LI Z, ZHANG K, et al. ChatDoctor: A medical chat model fine-tuned on a large language model meta-AI (LLaMA) using medical domain knowledge[J]. *Cureus*, 2023, 15(6): e40895.
- [12] HUANG J, YANG D M, RONG R, et al. A critical assessment of using ChatGPT for extracting structured data from clinical notes[J]. *NPJ Digit Med*, 2024, 7(1): 106.
- [13] SINGHAL K, AZIZI S, TU T, et al. Large language models encode clinical knowledge[J]. *Nature*, 2023, 620(7972): 172-180.
- [14] ZHOU Y, CHIA M A, WAGNER S K, et al. A foundation model for generalizable disease detection from retinal images[J]. *Nature*, 2023, 622(7981): 156-163.
- [15] ZHANG Y, DONG Y, MEI Z, et al. Performance of large language models on benign prostatic hyperplasia frequently asked questions[J]. *Prostate*, 2024, 84(9): 807-813.
- [16] BENÍTEZ T M, XU Y, BOUDREAU J D, et al. Harnessing the potential of large language models in medical education: Promise and pitfalls[J]. *J Am Med Inform Assoc*, 2024, 31(3): 776-783.
- [17] TRUHN D, WEBER C D, BRAUN B J, et al. A pilot study on the efficacy of GPT-4 in providing orthopedic treatment recommendations from MRI reports[J]. *Sci Rep*, 2023, 13(1): 20159.
- [18] KRESEVIC S, GIUFFRÈ M, AJCEVIC M, et al. Optimization of hepatological clinical guidelines interpretation by large language models: A retrieval augmented generation-based framework[J]. *NPJ Digit Med*, 2024, 7(1): 102.
- [19] GUO E, GUPTA M, SINHA S, et al. neuroGPT-X: Toward a clinic-ready large language model[J]. *J Neurosurg*, 2023, 140(4): 1041-1053.
- [20] WONG M, LIM Z W, PUSHPANATHAN K, et al. Review of emerging trends and projection of future developments in large language models research in ophthalmology[J]. *Br J Ophthalmol*, 2024, 108(10): 1362-1370.
- [21] 王 耀. 联勤保障部队第 940 医院成功接入 DeepSeek 大模型[EB/OL]. (2025-02-25)[2025-05-07]. <https://www.gsjb.com/system/2025/02/24/031142283.shtml>.
- [22] ONG H, ONG J, CHENG R, et al. GPT technology to help address longstanding barriers to care in free medical clinics[J]. *Ann Biomed Eng*, 2023, 51(9): 1906-1909.
- [23] DENECKE K, MAY R, LLM Health Group, et al. Potential of large language models in health care: Delphi study[J]. *J Med Internet Res*, 2024, 26: e52399.
- [24] LUO M J, PANG J, BI S, et al. Development and evaluation of a retrieval-augmented large language model framework for ophthalmology[J]. *JAMA Ophthalmol*, 2024, 142(9): 798-805.
- [25] 颜见智,何雨鑫,骆子烨,等. 生成式大语言模型在医疗领域的潜在典型应用与面临的挑战[J]. *医学信息学杂志*, 2023, 44(9): 23-31.
- [26] 界面新闻. 深度: 守紧大模型时代医疗数据安全与伦理“闸口”[EB/OL]. (2025-04-23)[2025-05-06]. <https://baijiahao.baidu.com/s?id=1830151388636368265&wfr=spider&for=pc>.
- [27] ZACK T, LEHMAN E, SUZGUN M, et al. Assessing the potential of GPT-4 to perpetuate racial and gender biases in health care: A model evaluation study[J]. *Lancet Digit Health*, 2024, 6(1): e12-e22.
- [28] GALLEGOS I O, ROSSI R A, BARROW J, et al. Bias and Fairness in Large Language Models: A Survey[J]. *Computational Linguistics* 2024, 50 (3): 1097-1179.
- [29] 第一财经. 独家: 对话协和: 国内首款罕见病大模型, 如何抑制 AI “幻觉”?[EB/OL]. (2025-02-28)[2025-05-06]. <https://baijiahao.baidu.com/s?id=1825291701545844037&wfr=spider&for=pc>.
- [30] 黄一洲, 谭郑雨. 生成式人工智能对于医患关系的伦理重构[J]. *医学与哲学*, 2024, 45(3): 49-53.
- [31] 刘金瑞. 生成式人工智能大模型的新型风险与规制框架[J]. *行政法学研究*, 2024(2): 17-32.
- [32] 封面新闻. 与真人医生诊断一致性达 96%: AI 医生应用前景广阔[EB/OL]. (2023-07-03)[2025-05-06]. https://m.baidu.com/bh/m/detail/ar_8786243128681146382.
- [33] 文汇报. 瑞金医院携手华为发布瑞智病理大模型 RuiPath, 单切片 AI 诊断仅需数秒[EB/OL]. (2025-02-18)[2025-05-06]. <https://baijiahao.baidu.com/s?id=1824405959304681514&wfr=spider&for=pc>.
- [34] CHEN I Y, JOSHI S, GHASSEMI M. Treating health disparities with artificial intelligence[J]. *Nat Med*, 2020, 26(1): 16-17.
- [35] ALSENTZER E, RASMUSSEN M J, FONTOURA R, et al. Zero-shot interpretable phenotyping of postpartum hemorrhage using large language models[J]. *NPJ Digit Med*, 2023, 6(1): 212.
- [36] 肖仰华, 徐一丹. 大规模生成式语言模型在医疗领域的应用: 机遇与挑战[J]. *医学信息学杂志*, 2023, 44(9): 1-11.

收稿日期: 2024-07-31

修回日期: 2025-06-03

(本文编辑: 邹明明)