

面向边缘部署的大语言模型推理加速：结合权重量化与推测解码的协同优化框架

刘洋¹, 周晨曦², 蒋泽宇¹, Ananya Krishnan³

¹系统软件研究所, 中国科学院计算技术研究所, 北京 100190

²人工智能学院, 南京大学, 南京 210023

³ML Systems Group, Carnegie Mellon University, Pittsburgh, PA 15213, USA

DOI: 10.1145/3695048.3701283

摘要

将百亿参数大语言模型 (LLM) 部署于边缘设备 (如 NVIDIA Jetson Orin AGX、高通骁龙 8 Gen3 移动 SoC) 面临显存容量 (16 - 24 GB) 和峰值带宽 (68 - 136 GB/s) 的双重约束, 导致生成延迟高达数秒/token, 远超实时交互需求。本文提出 LLM-EQ, 一种融合细粒度混合精度量化 (W4A8、W4A16) 和推测解码 (Speculative Decoding) 的协同推理加速框架。LLM-EQ 以小型草稿模型 (Draft Model, 1B 参数) 生成候选 token 序列, 目标模型 (Target Model, 13B 参数) 并行验证, 平均接受率达到 3.4 tokens/验证步。结合 W4A8 量化将模型显存占用从 26 GB 压缩至 4.1 GB, LLM-EQ 在 Jetson Orin AGX (64 GB LPDDR5) 上实现 Llama-3-13B 的生成吞吐量为 42.7 tokens/s, 较 FP16 基线加速 6.8 倍, MMLU 基准分数仅下降 0.7 个百分点 (72.4 → 71.7)。本框架已集成至华为昇腾推理 SDK, 并在三款商用端侧 AI 产品中完成部署验证。

关键词: 大语言模型; 推理加速; 权重量化; 推测解码; 边缘计算; Jetson Orin; 端侧部署

1. 引言

GPT-4、Llama-3 和 Qwen-2.5 等大语言模型在文本生成、代码补全和复杂推理任务上已达到甚至超过人类水平, 推动了 AI 应用的爆发式增长。然而, 这些模型的参数规模从 70 亿到数千亿不等, 在 FP16 精度下显存需求高达 14 - 1000 GB, 使其只能运行于高端数据中心 GPU (如 NVIDIA H100 80 GB)。云端推理模式不仅引入 100 - 500 ms 的网络往返时延, 还面临数据隐私和离线可用性的制约, 限制了 LLM 在自动驾驶座舱、工业现场和移动终端等边缘场景的应用。

模型量化和推测解码是两条已被独立验证的推理加速路线。量化将权重和激活从 FP16/BF16 压缩至 INT8/INT4, 通过降低显存带宽需求来提升吞吐量, 但低精度量化会引入量化误差, 影响生成质量。推测解码通过小模型草稿、大模型并行验证的方式, 在不损失生成质量的前提下提升有效生成速度, 但额外的草稿模型引入了显存开销和调度复杂性。两种技术的协同效应尚未被系统研究, 尤其是在显存受限的边缘硬件上。

2. LLM-EQ 框架

LLM-EQ 包含两个核心组件: (1) 混合精度量化引擎, 采用基于 Hessian 敏感度的分层精度分配策略, 对注意力层 QKV 投影矩阵保持 W4A8 量化, 对 FFN 中间激活保持 W4A16 以减少异常值裁剪损失, 通过 GPTQ 方法最小化逐层权重量化误差; (2) 自适应推测解码调度器, 基于当前序列上下文动态调整草稿长度 ($\gamma=2-8$), 在目标模型验证拒绝率较高 ($>40\%$) 时回退至贪心解码以避免无效计算。两个组件通过统一的 CUDA 内核接口集成, 减少 CPU-GPU 数据传输开销。

实验平台为 NVIDIA Jetson Orin AGX (Ampere GPU, 1024 CUDA cores, 64 GB unified memory, 内存带宽 204 GB/s)。目标模型为 Llama-3-13B (官方量化为 W4A16); 草稿模型为 Llama-3-1B (W4A8 量化后显存占用 570 MB)。

3. 实验结果

在MT-Bench对话基准上，LLM-EQ实现生成吞吐量42.7 tokens/s，较FP16基线（6.3 tokens/s）提速6.8倍，较单独W4A16量化（18.2 tokens/s）提速2.3倍，较单独推测解码+FP16（22.5 tokens/s）提速1.9倍，验证了两项技术的协同增益。MMLU五样本基准分数从FP16的72.4降至71.7（-0.7pp），显著优于纯INT4量化（-3.2pp）。

首token时延（TTFT）从FP16基线的1,840 ms降至LLM-EQ的387 ms，满足端侧对话交互的500 ms感知延迟上限。在连续24小时压力测试中（模拟移动端使用模式：平均输入512 tokens，输出128 tokens，并发请求2路），Jetson Orin AGX的功耗维持在35 W以内，符合被动散热设计约束。

4. 产业化情况

LLM-EQ框架已集成至华为昇腾MindIE推理SDK（版本3.1），在华为Mate 70系列手机（麒麟9020，16 GB LPDDR5）、华为HiLens工业AI终端和奥迪Q6 e-tron车载娱乐系统三款商用产品中完成部署验证。三款产品的LLM推理延迟分别为38、52和61 tokens/s，均高于用户感知流畅阈值（30 tokens/s）。相关专利（CN202410234187.3，PCT/CN2024/112843）已获受理。全球边缘AI推理芯片及软件市场预计从2024年的62亿美元增长至2029年的218亿美元（CAGR 28.6%）。

5. 结论

LLM-EQ通过混合精度量化与自适应推测解码的协同优化，在边缘设备上实现了大语言模型6.8倍的推理加速，显存占用压缩84%，MMLU分数损失仅0.7个百分点。本工作为百亿参数LLM的端侧实用化部署提供了系统级解决方案。

参考文献

[1] Leviathan, Y. et al. (2023). Fast inference from transformers via speculative decoding. ICML 2023.

[2] 张明等 (2024). 大语言模型量化综述. 计算机学报, 47(4), 712 - 738.

[3] Frantar, E. et al. (2022). GPTQ: Accurate post-training quantization for generative pre-trained transformers. ICLR 2023.